

OPTIMIZACION DE COSTOS - ENTREGABLE 20%

Matriz de decision de modelos de IA

Proyecto: registro y asignacion de turnos desde Google Forms, orquestado en Make, con OpenAI, Google Calendar, Airtable, Gmail e intervencion humana (HITL).

Decision ejecutiva. El escenario productivo debe usar **GPT-4o-mini en modo sincronico** solo para validar y estructurar los datos del formulario. La disponibilidad, la creacion del turno y los correos se resuelven sin IA. **Claude Sonnet** queda como alternativa condicional para lectura documental extensa, y **Batch** para trabajos masivos que no requieren respuesta inmediata.

1. EN PRODUCCION

GPT-4o-mini

Validacion semantica breve, clasificacion y salida JSON. Rapido, economico y ya integrado en Make.

2. SIN MODELO

Reglas + Calendar

Fechas, horarios, disponibilidad, eventos y plantillas de correo son deterministas: no justifican pagar tokens.

3. SOLO SI CAMBIA LA CARGA

Claude / Batch

Claude para documentos densos; Batch para miles de registros asincronicos. No forman parte del turno en tiempo real.

Regla de seleccion

A	B	C	D	E
¿Es una regla exacta?	¿Es texto breve y necesita JSON ahora?	¿Es un documento largo o denso?	¿Es ambiguo o de impacto clinico?	¿Son miles de casos y pueden esperar?
Usar Make / Calendar / filtro. Sin IA.	Usar GPT-4o-mini sincronico.	Evaluar Claude Sonnet de forma puntual.	Derivar a la doctora: HITL.	Usar Batch fuera del flujo en tiempo real.

Criterio rector: **no se paga razonamiento probabilistico para resolver datos que una regla o una API determinista pueden responder con mayor precision.**

Matriz de decision por tarea

La matriz distingue el escenario actual de las alternativas futuras. 'Condicional' significa que la opcion solo se habilita cuando se cumple el disparador indicado; no se agrega por defecto al escenario de Make.

Tarea del proceso	Naturaleza	Seleccion	Modalidad	Costo IA	Justificacion	Cuando cambiar
Validar nombre, edad, email, día, hora y pedido especial	Semantica breve + clasificacion	GPT-4o-mini	Sincronica, una llamada	Muy bajo	Suficiente para datos cortos, salida JSON y respuesta inmediata.	Subir de modelo solo si una evaluacion demuestra errores persistentes.
Normalizar la respuesta para el router	Estructuracion	Misma llamada GPT-4o-mini	Structured Output / JSON	Sin llamada adicional	La validacion y la estructura se resuelven en una sola inferencia.	No separar en dos llamadas salvo necesidad comprobada.
Comprobar disponibilidad	Regla exacta	Google Calendar	FreeBusy / busqueda	USD 0 de modelo	El calendario es la fuente real; un LLM podria inventar disponibilidad.	No cambiar a IA.
Crear evento y guardar identificador	Operacion transaccional	Google Calendar + Airtable	API / modulos Make	USD 0 de modelo	Escritura determinista y auditable.	No cambiar a IA.
Confirmar turno o pedir otro horario	Mensaje repetible	Plantilla Gmail	HTML fijo + campos mapeados	USD 0 de modelo	El contenido debe ser estable, claro y verificable.	Usar IA solo para traduccion o personalizacion autorizada.
Pedido especial del paciente	Excepcion / contexto humano	HITL: doctora	Email de aviso	USD 0 de modelo	Evita delegar decisiones sensibles o ambiguas al modelo.	La IA puede resumir, pero la decision sigue siendo humana.
Lectura de historias o documentos muy extensos	Documento denso	Claude Sonnet 4.6	Condicional, fuera del turno	Alto	Ventana amplia y buena alternativa para lectura extensa; no se necesita en el formulario actual.	Activar solo si se incorporan archivos largos y hay prueba de calidad.
Excepcion compleja / auditoria de baja frecuencia	Razonamiento superior	GPT-4o + HITL	Bajo demanda	Medio	Mayor capacidad que el modelo mini; se reserva para casos dificiles.	Usar solo tras filtro de confianza o revision fallida.
Clasificar o reevaluar miles de registros historicos	Volumen masivo no urgente	GPT-4o-mini Batch	Asincronica, hasta 24 h	50% menor	Reduce costo y usa limites separados; no sirve para confirmar turnos en tiempo real.	Activar desde un escenario nocturno o proceso independiente.

Resultado: el unico costo de modelo en el recorrido normal es una llamada de GPT-4o-mini por respuesta procesada. Las demas decisiones se apoyan en sistemas de registro o en la doctora.

Comparacion ponderada y proyeccion economica

1. Matriz ponderada para la validacion semantica en tiempo real

Escala de 1 (desfavorable) a 5 (muy favorable). Los pesos reflejan este caso de uso: respuesta breve, JSON, bajo costo y conexion ya disponible en Make.

Alternativa	Adecuacion JSON 30%	Costo 30%	Latencia 15%	Integracion Make 15%	Docs densos 10%	Total / 5	Decision
GPT-4o-mini	5	5	5	5	3	4,80	SELECCIONADO
GPT-4o	5	3	4	5	4	4,15	Reserva compleja
Claude Sonnet 4.6	5	2	4	2	5	3,50	Docs extensos

2. Costos comparables

Supuesto comun para poder comparar: **1.000 tokens de entrada + 150 tokens de salida por solicitud**. Precios en USD por 1 millon de tokens consultados el 10/08/2026. No incluye Make, Airtable, Google, impuestos ni tipo de cambio.

Opcion	Entrada / 1M	Salida / 1M	Costo por solicitud	1.000 solicitudes	10.000	100.000	Uso
Reglas / Calendar / Gmail	USD 0,00	USD 0,00	USD 0,00	USD 0,00	USD 0,00	USD 0,00	Determinista
GPT-4o-mini sincronico	USD 0,15	USD 0,60	USD 0,00024	USD 0,24	USD 2,40	USD 24,00	Produccion
GPT-4o-mini Batch	USD 0,075	USD 0,30	USD 0,00012	USD 0,12	USD 1,20	USD 12,00	Masivo, no urgente
GPT-4o sincronico	USD 2,50	USD 10,00	USD 0,00400	USD 4,00	USD 40,00	USD 400,00	Reserva compleja
Claude Sonnet 4.6	USD 3,00	USD 15,00	USD 0,00525	USD 5,25	USD 52,50	USD 525,00	Docs extensos

Lectura del costo: con el supuesto anterior, 10.000 validaciones cuestan aproximadamente **USD 2,40 con GPT-4o-mini**, frente a **USD 40,00 con GPT-4o**. Batch reduciria el modelo mini a unos **USD 1,20**, pero no puede usarse para confirmar un turno en el momento.

Politica operativa de optimizacion

La optimizacion se controla con reglas de arquitectura, medicion y escalamiento. Limitar tokens es una medida complementaria, no la matriz de decision.

Aplicacion inmediata en el escenario Make

Modulo OpenAI: mantener **gpt-4o-mini**, temperatura baja, salida JSON y un maximo de salida coherente con cuatro campos de decision.

Una sola llamada: validar, detectar HITL y producir *solicitud_valida*, *requiere_humano*, *observaciones* y *mensaje_paciente* en la misma respuesta.

Sin IA: filtros del router, rango lunes-viernes 16:00-20:00, consulta FreeBusy, creacion del evento, escritura en Airtable y correos Gmail.

Batch: no se agrega a este escenario. Si aparece una carga historica masiva, se crea un proceso asincronico independiente para no bloquear turnos.

Disparadores de cambio

Pasar a GPT-4o solo si un conjunto de prueba revisado muestra que GPT-4o-mini no alcanza el umbral de calidad definido.

Agregar Claude Sonnet solo si el alcance incorpora historias, estudios o documentos densos y una comparacion real demuestra ventaja suficiente para justificar otra conexion y otro proveedor.

Activar Batch cuando el trabajo sea repetitivo, masivo, no urgente y separable del recorrido en tiempo real; por ejemplo, reevaluar registros historicos.

Derivar a HITL ante ambigüedad, pedido especial, informacion clinica sensible o una decision que no sea meramente administrativa.

Indicadores de control mensual

Indicador	Meta inicial	Accion si se desvía
Llamadas de IA por formulario	1	Eliminar llamadas duplicadas o prompts encadenados.
Salida JSON valida	>= 98%	Corregir esquema/prompt antes de subir de modelo.
Casos derivados a HITL	Medir, sin forzar minimo	Revisar causas; no bajar HITL si compromete seguridad.
Costo medio de IA por solicitud	Cercano al supuesto medido	Comparar tokens reales, prompt y longitud de salida.
Errores de disponibilidad por IA	0	La disponibilidad debe permanecer en Calendar, no en el LLM.

Fuentes y alcance de los precios

- [1] OpenAI, GPT-4o mini: <https://developers.openai.com/api/docs/models/gpt-4o-mini>
- [2] OpenAI, GPT-4o: <https://developers.openai.com/api/docs/models/gpt-4o>
- [3] OpenAI, Batch API (50% de descuento; ventana de hasta 24 h): <https://developers.openai.com/api/docs/guides/batch>
- [4] Anthropic, Claude Platform pricing (Claude Sonnet 4.6 y Batch): <https://platform.claude.com/docs/en/about-claude/pricing>

Nota: los precios de API pueden cambiar. Las cifras son comparativas, estan expresadas en USD y deben actualizarse antes de una contratacion o presupuesto definitivo. La seleccion no autoriza al modelo a diagnosticar ni a decidir cuestiones clinicas.